昇腾910C训练集群并行策略对MFU影响的技术分析报告

1 研究背景

在基于昇腾910C训练集群开展大模型训练的过程中，计划进行算力规模扩展（Scaling）。在Scaling过程中，并行策略的选择对训练效率具有直接影响。本报告围绕以下方面展开研究：

- 张量并行（TP）与流水线并行（PP）在增大过程中对MFU变化程度的影响差异，以及算力Scaling后上述变化趋势的演变规律；
- 大TP配置在Scaling后对MFU影响更显著的底层原因；
- 配置调整后MFU提升的归因分析；
- 在给定集群规模下最优并行度配置的选择。

2 TP与PP对MFU变化趋势的影响分析

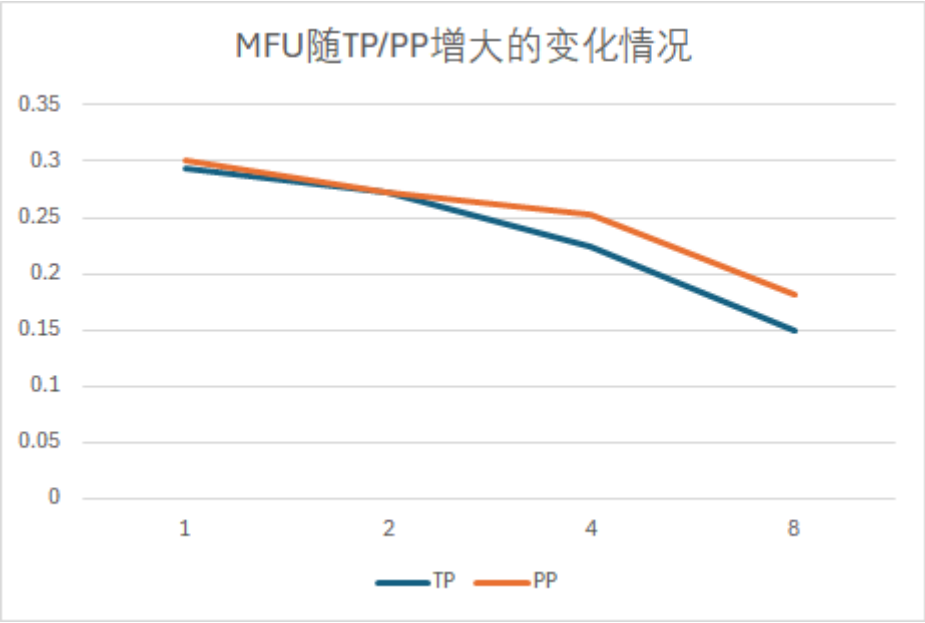
2.1 实验一：TP/PP增大对MFU的变化曲线

2.1.1 实验设计

本实验采用控制变量法，分别固定PP和TP，逐步增大另一并行维度，观察MFU的变化趋势：

实验组	固定参数	变化参数	取值范围
A组（蓝线）	PP = 2	TP	1, 2, 4, 8
B组（橙线）	TP = 2	PP	1, 2, 4, 8

2.1.2 实验结果



> **图1说明**：蓝线表示PP固定为2时，TP在1/2/4/8取值下的MFU变化；橙线表示TP固定为2时，PP在1/2/4/8取值下的MFU变化。横坐标为TP/PP取值，纵坐标为MFU。

2.1.3 小结

从实验结果可以观察到，**增大TP对MFU的影响明显大于增大PP。**两组的平均变化率对比如下：

并行维度	平均MFU变化率
增大TP（PP固定为2）	19.36%
增大PP（TP固定为2）	14.99%

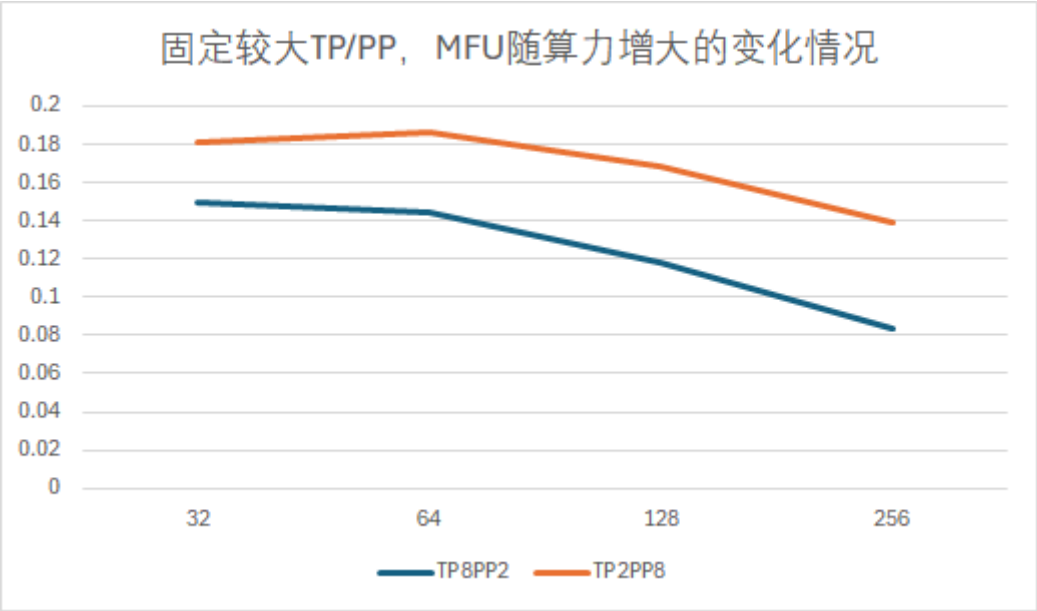
2.2 实验二：算力Scaling后大TP/大PP对MFU的影响

2.2.1 实验设计

基于实验一观察到的现象，进一步在较大并行度（TP8和PP8）下，验证算力Scaling对MFU的影响：

实验组	固定并行配置	变化参数（world size）	取值范围
A组（蓝线）	TP = 8	world size	32, 64, 128, 256
B组（橙线）	PP = 8	world size	32, 64, 128, 256

2.2.2 实验结果



> **图2说明**：蓝线表示TP8在world size为32/64/128/256时的MFU变化；橙线表示PP8在相同world size下的MFU变化。横坐标为world size，纵坐标为MFU。

2.2.3 小结

随着训练算力规模增大，**TP8对MFU的影响明显大于PP8**，与实验一的趋势一致。两组的平均变化率对比如下：

并行配置	平均MFU变化率
TP8（Scaling后）	17.17%
PP8（Scaling后）	8.08%

2.3 本节结论

综合实验一与实验二，在两种实验条件下均验证了同一结论：**增大TP对MFU的影响显著大于增大PP。**该结论为后续根因分析提供了方向——需聚焦大TP配置在Scaling后对MFU产生更显著影响的底层机制。

---

3 大TP下MFU变化的根因分析

3.1 分析概述

基于第2章的实验结论——大TP在Scaling后对MFU的影响更为显著，本章对该现象进行根因分析。通过TensorBoard与Profiling数据，从通信开销与时延两个维度展开逐层剖析。

3.2 根因总结

大TP在Scaling后影响MFU的原因可归纳为以下两个层面：

根因层面	具体表现
通信量增加	Scaling后未重叠通信量显著增加
通信时延变化	（1）forward阶段TP小消息AllReduce延迟增加4～19倍，而大消息AllReduce基本不变； （2）iteration尾部的ReduceScatter因DP Scaling而增加，且大TP较大PP Scaling后增加更为明显

3.3 详细分析过程

3.3.1 forward阶段耗时增长较为集中

对TensorBoard结果进行分析，TP8在Scaling后forward-compute耗时增长约**3.1倍**，而对照组TP2PP8仅增长**1.83倍**，表明耗时增长主要集中在forward阶段。

配置	forward-compute Scaling后增长倍数
TP8	~3.1倍
TP2PP8	~1.83倍

3.3.2 forward-compute增长来自于通信

对Profiling结果进行分析，Scaling后计算（Computing）耗时基本不变，说明计算算子本身性能稳定。但Scaling后**未重叠的通信有所增长**：

配置	未重叠通信Scaling后增长率
TP8	120%
TP2PP8	54%

这表明forward-compute的增长主要源于通信开销，而非计算开销。

3.3.3 通信耗时增长集中在小消息AllReduce

将同一TP通信组内Scaling前后的AllReduce逐一对比，发现：

- **大消息AllReduce**：耗时基本不变；
- **小消息AllReduce**：耗时增加数倍以上。

小消息传输数据量小，固定开销占比高，因此对Scaling更加敏感。这是大TP通信耗时增长的主要来源之一。

3.3.4 ReduceScatter在大TP下增长更明显

在两种TP配置下，ReduceScatter均随DP增大有所增长，但TP8下的耗时增长约为TP2PP8的**4倍**。原因分析如下：

- TP8PP2的流水线较浅，backward阶段几乎同时结束；
- DP组发射ReduceScatter较为集中，导致瞬间通信流量较高，增加网络负载。

配置	ReduceScatter耗时增长相对倍数
TP8	基准（增长更明显）
TP2PP8	约为TP8的1/4

3.3.5 大TP通信重叠效率下降的原因

通信重叠效率下降（即计算掩盖通信的能力减弱）的原因可从以下两方面理解：

1. **计算窗口更短**：在256 die规模下，TP8的平均compute算子耗时约为TP2PP8的**1/3**，单个计算窗口可隐藏的通信时长更短。
2. **通信时延增加**：TP8的平均compute算子耗时在Scaling前后基本未变，但Scaling前通信延迟较低，可以掩盖部分通信；Scaling后通信时延增加，导致计算更加难以有效掩盖通信。

因素	Scaling前	Scaling后
TP8平均compute算子耗时	基本未变	基本未变
通信延迟	较低，可部分掩盖	有所增加，难以掩盖
计算窗口可隐藏通信时长	相对充足	相对不足（约为TP2PP8的1/3）

---

4 最新配置的验证与归因分析

4.1 背景

将并行度调整为TP8PP8，同时将全局批大小（GBS）从1024增加到8192，并将重计算策略从uniform1（全层重计算）改为block1（每PP stage仅第1层重计算）后，观察到MFU有所提升，由此对第2～3章得出的"大TP在Scaling后对MFU的影响更加显著"的结论产生质疑。

为此，本章针对该最新配置重新进行分析与实验，旨在厘清MFU提升的真正来源。

4.2 实验环境

项目	内容
测试集群	vc-a3-241ceshi
硬件规模	2048 die
基础配置	TP8 / PP8 / VPP4

4.3 实验结果与分析

4.3.1 增大GBS可提升MFU

在2048 die上，按照所提供的脚本（TP8/PP8/VPP4/GBS1024）进行测试，MFU约为20.7%，与反馈结果基本一致。在此基础上，仅将GBS从1024改为8192，其余配置不变，MFU提升至约24.1%。

配置	GBS	MFU
TP8/PP8/VPP4	1024	~20.7%
TP8/PP8/VPP4	8192	~24.1%

结论：增大GBS可以提升MFU，GBS8192较GBS1024提升约3.4个百分点。

4.3.2 Scaling后MFU变化分析

为验证Scaling对MFU的影响，将GBS8192配置在1024 die上进行测试，MFU为26%；Scaling到2048 die后，MFU降低约2个百分点。

硬件规模	MFU	变化幅度
1024 die	~26%	—
2048 die	~24%	~2个百分点

结论：Scaling后MFU存在一定程度的降低。 这属于算力规模扩展过程中的常见现象，通过针对性优化并行配置参数，可以有效缩小该影响。

4.3.3 MFU提升来自重计算层数减少，而非TP8

将重计算策略从uniform1改为block1后，MFU有所提升。经分析，该提升应归因于重计算层数的减少，而非TP8配置本身。两种策略的重计算层数对比如下：

重计算策略	含义	PP8重计算层数	PP64重计算层数
uniform1	全层重计算（每层均重计算）	128层	128层
block1	每PP stage仅第1层重计算	8层	64层

从uniform1改为block1时，重计算层数显著减少，MFU自然提升。两种并行配置下的提升幅度对比如下：

并行配置	uniform1 MFU	block1 MFU	提升幅度
TP8PP8	24.1%	28.1%	+4.0个百分点
TP1PP64	26.7%	27.0%	+0.3个百分点

分析：重计算层数减少后，两种配置的MFU均有提升，但TP8PP8+block1的收益明显更大。其原因是：对于block1，PP8重计算8层，PP64重计算64层。PP8从uniform1改为block1相当于少重计算120层，而PP64仅少重计算64层。因此，TP8PP8+block1的收益更大应归因于重计算层数减少幅度更大，而不应归结于TP8PP8配置本身优于TP1PP64。

4.4 本节结论

议题	结论
增大GBS是否提升MFU	是，GBS8192较GBS1024提升约3.4个百分点
Scaling后MFU变化	存在一定降低（1024 die→2048 die降低约2个百分点），可通过配置优化有效缓解
MFU提升的真正来源	GBS增加和重计算层数减少，而非TP8配置
TP8PP8+block1收益更大的原因	PP8从uniform1改为block1少重计算120层，远多于PP64的64层

综上，第2～3章得出的"大TP在Scaling后对MFU的影响更加显著"的结论依然成立。上述观察到的MFU提升由GBS增大与重计算策略调整带来，与TP8配置无直接因果关系。

---

5 最优并行度配置搜索

5.1 搜索思路

基于前述分析结论：

1. TP8并非最优并行方式（大TP在Scaling后对MFU影响更显著）；
2. TP1PP64存在PP取值过大的情况。

因此，理论上通过缩小TP和PP，可以找到一个MFU最优的平衡点。本章在2048 die规模下，对多组不同并行度进行网格搜索消融实验，以寻找最优配置。

5.2 实验条件

项目	内容
硬件规模	2048 die
GBS	8192
MBS	1
VPP	2
模型参数规模	200B（基于Qwen3）

5.3 实验结果

序号	TP	PP	重计算策略	TP×PP	MFU
1	1	64	uniform1	64	26.7%
2	2	32	uniform1	64	30.4%
3	4	16	uniform1	64	29.8%
4	**2**	**16**	**uniform1**	**32**	**33.4%**
5	4	8	uniform1	32	31.3%
6	8	8	uniform1	64	24.1%
7	8	8	block1	64	28.1%

5.4 结果分析

基于上述实验结果，可以得出以下分析：

1. **PP过大会降低MFU**：PP64过大，将PP缩小到合理值后MFU有明显提升。例如，同等TP×PP=64条件下，TP1PP64（26.7%）显著低于TP2PP32（30.4%）和TP4PP16（29.8%）。
2. **TP过大会降低MFU**：TP8过大，在同等TP×PP乘积下，MFU随TP增大而降低。例如，TP×PP=64时，TP2PP32（30.4%）> TP4PP16（29.8%）> TP8PP8（24.1%）。
3. **最优配置为TP2PP16（uniform1）**：在本次实验条件下，TP2PP16（uniform1）取得最高MFU 33.4%。
4. **TP8PP8（block1）可作为基线**：该配置结果较为稳定（28.1%），可作为性能基线参考。但该值并非最优，且在显存允许的前提下，还可以进一步减少重计算层数，MFU仍有提升空间。